This code has part of the paper entitled: "A Data-Driven Approach to Predicting Electric Load Profiles in a Quicklime Company"

```python
import pandas as pd


df = pd.read_csv('dataset_limpio_carga_laboral.csv')

# Mostrar el DataFrame
print(df.head())
```

```
   perfil_carga  global_active_power  global_reactive_power     voltage  \
0           0.0                  0.0                    0.0  220.537667
1           0.0                  0.0                    0.0  218.650113
2           0.0                  0.0                    0.0  220.671497
3           0.0                  0.0                    0.0  220.888396
4           0.0                  0.0                    0.0  219.897758

   global_intensity  Year  Month  Day  Hour  Minute
0               0.0  2023      1    1     0       0
1               0.0  2023      1    1     0      10
2               0.0  2023      1    1     0      20
3               0.0  2023      1    1     0      30
4               0.0  2023      1    1     0      40
```

```python
print(df.head())
```

```
   perfil_carga  global_active_power  global_reactive_power     voltage  \
0           0.0                  0.0                    0.0  220.537667
1           0.0                  0.0                    0.0  218.650113
2           0.0                  0.0                    0.0  220.671497
3           0.0                  0.0                    0.0  220.888396
4           0.0                  0.0                    0.0  219.897758

   global_intensity  Year  Month  Day  Hour  Minute
0               0.0  2023      1    1     0       0
1               0.0  2023      1    1     0      10
2               0.0  2023      1    1     0      20
3               0.0  2023      1    1     0      30
4               0.0  2023      1    1     0      40
```

```python
df
```

	perfil_carga	global_active_power	global_reactive_power	voltage	global_intensity	Year	Month	Day	Hour	Minute
0	0.0	0.0	0.0	220.537667	0.0	2023	1	1	0	0
1	0.0	0.0	0.0	218.650113	0.0	2023	1	1	0	10
2	0.0	0.0	0.0	220.671497	0.0	2023	1	1	0	20
3	0.0	0.0	0.0	220.888396	0.0	2023	1	1	0	30
4	0.0	0.0	0.0	219.897758	0.0	2023	1	1	0	40
...	...	...	...	...	...	...	...	...	...	...
52555	0.0	0.0	0.0	219.747224	0.0	2023	12	31	23	10
52556	0.0	0.0	0.0	217.300853	0.0	2023	12	31	23	20
52557	0.0	0.0	0.0	220.549853	0.0	2023	12	31	23	30
52558	0.0	0.0	0.0	220.566343	0.0	2023	12	31	23	40
52559	0.0	0.0	0.0	222.274435	0.0	2023	12	31	23	50

52560 rows × 10 columns

Pasos siguientes: Generar código con df | Ver gráficos recomendados | New interactive sheet

```python
# Importar bibliotecas necesarias
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt



# Calcular la matriz de correlación
```

```python
corr_matrix = df.corr()

# Crear la gráfica del mapa de calor (heatmap) con seaborn
plt.figure(figsize=(10, 8))  # Ajustar el tamaño de la figura
sns.heatmap(corr_matrix, annot=True, cmap="coolwarm", vmin=-1, vmax=1)

# Agregar título a la gráfica
plt.title("Correlation Matrix of Variables")


# Guardar la gráfica en un archivo PDF
plt.savefig("correlation_matrix.pdf", format="pdf", bbox_inches="tight")

# Mostrar la gráfica
plt.show()

```

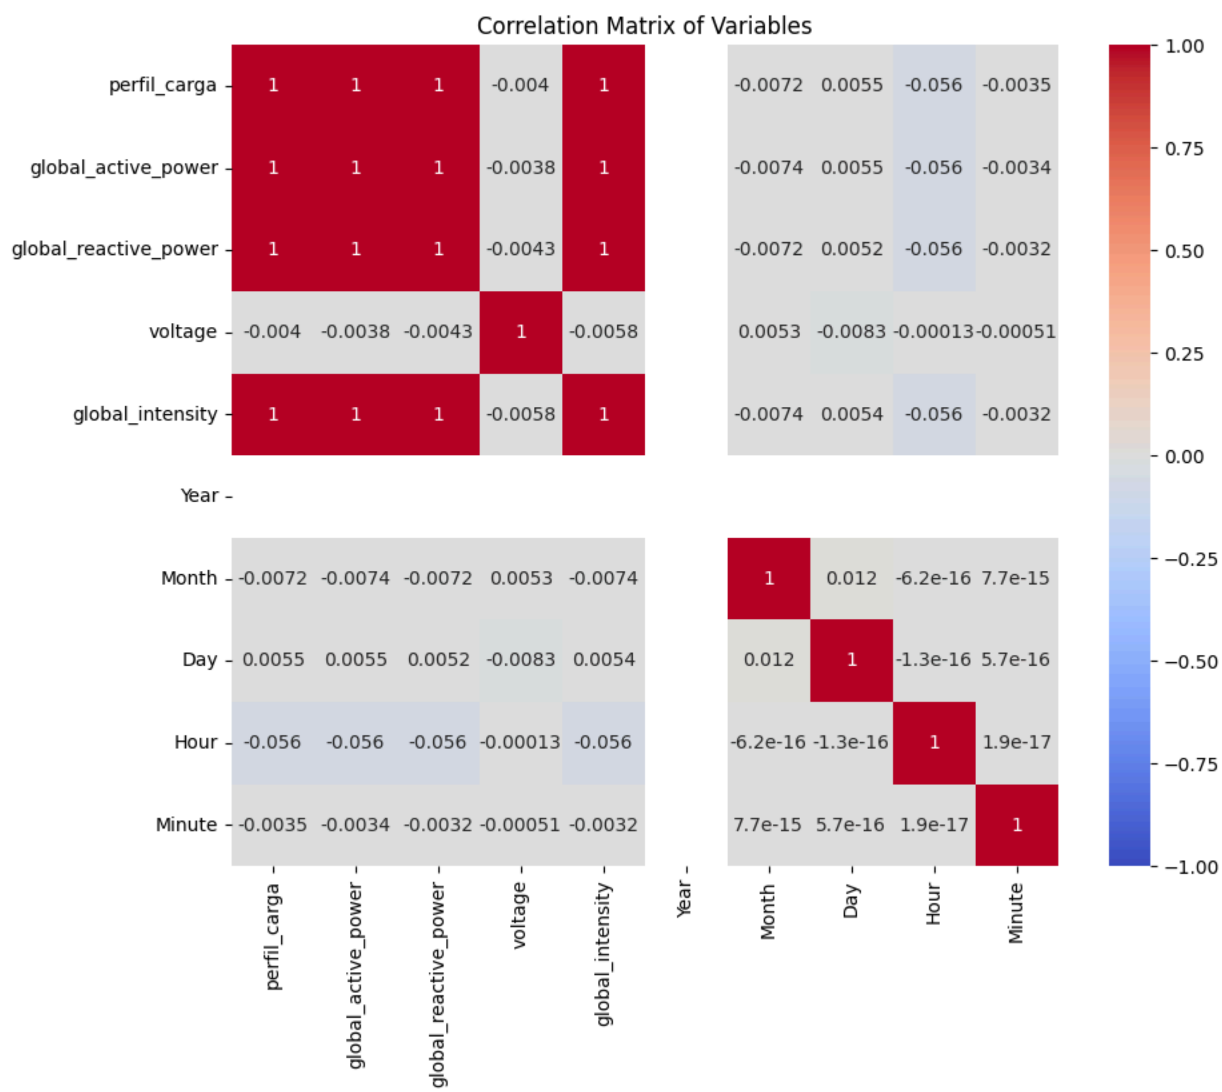

Arimax Model

```python
import pandas as pd
import matplotlib.pyplot as plt
from statsmodels.tsa.arima.model import ARIMA
from sklearn.metrics import mean_squared_error
import numpy as np

# Supongamos que 'df' es tu DataFrame con los datos

# Separar las características exógenas y la variable objetivo
X_exog = df.drop('perfil_carga', axis=1)  # Variables exógenas
y = df['perfil_carga']  # Variable objetivo (perfil_carga)
```

```python

# División basada en el tiempo (80% entrenamiento, 20% prueba)
train_size = int(len(y) * 0.8)
X_train_exog, X_test_exog = X_exog[:train_size], X_exog[train_size:]
y_train, y_test = y[:train_size], y[train_size:]

# Ajustar el modelo ARIMAX en los datos de entrenamiento
# order=(p,d,q) se puede ajustar según los datos, aquí es un ejemplo con (5,1,0)
model = ARIMA(y_train, order=(5, 1, 0), exog=X_train_exog)
model_fit = model.fit()

# Hacer predicciones sobre los datos de prueba, con las variables exógenas
start = len(y_train)
end = len(y_train) + len(y_test) - 1
predictions = model_fit.predict(start=start, end=end, exog=X_test_exog, typ='levels')

# Calcular el RMSE entre los valores reales y las predicciones
rmse = np.sqrt(mean_squared_error(y_test, predictions))
print(f'RMSE: {rmse}')

# Graficar el perfil de carga real vs predicho
plt.figure(figsize=(10, 6))
plt.plot(y_test.index, y_test, label='Real Data', color='blue')
plt.plot(y_test.index, predictions, label='ARIMAX Prediction', color='red')
plt.title('ARIMAX Prediction vs Real Data')
plt.xlabel('Time')
plt.ylabel('Load profile')
plt.legend()

# Guardar la gráfica en un archivo PDF
plt.savefig("arimax_all.pdf", format="pdf", bbox_inches="tight")
plt.show()

```

```
/usr/local/lib/python3.10/dist-packages/statsmodels/tsa/statespace/representation.py:374: FutureWarning: Unknown keyword arguments: dict
  warnings.warn(msg, FutureWarning)
RMSE: 392.9646536128175
```

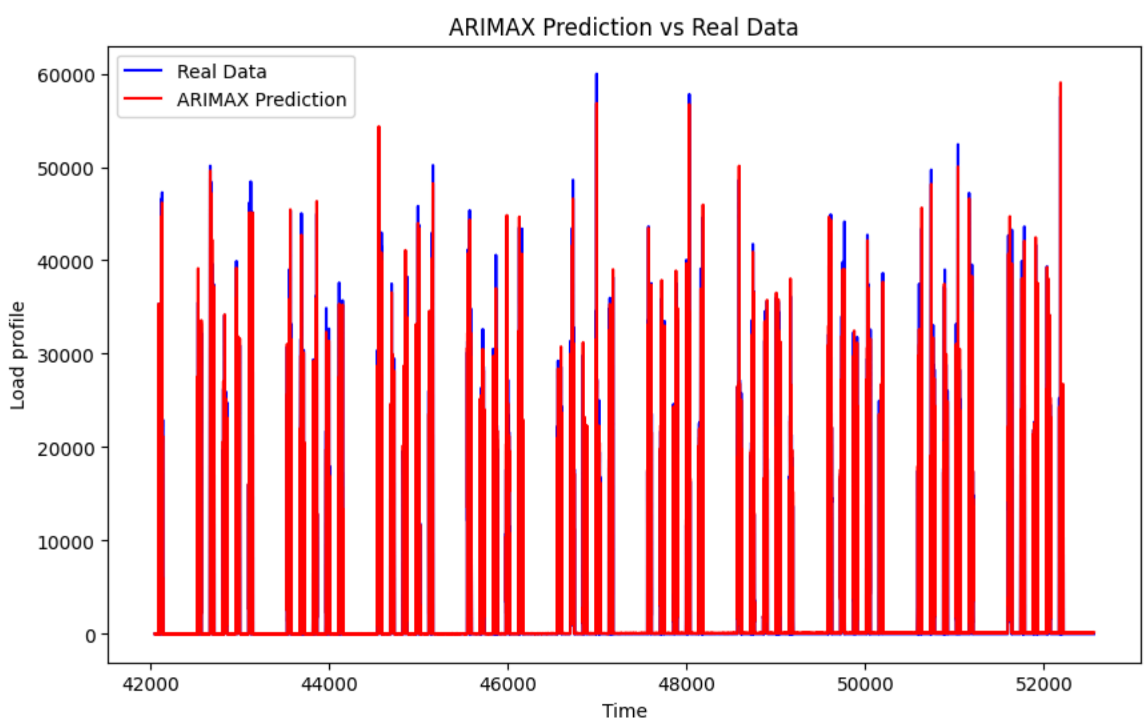


```python
# Graficar los últimos 2000 puntos de los valores reales vs predichos
plt.figure(figsize=(10, 6))
plt.plot(y_test.index[-2000:], y_test.values[-2000:], label='Real Data', color='blue')
plt.plot(y_test.index[-2000:], predictions[-2000:], label='ARIMAX Prediction', color='red')
plt.title('Comparison of Real vs Predicted Load Profiles in the Test Set: 14-Day Analysis with Two Weekends Using the ARIMAX Model')
plt.xlabel('Time')
plt.ylabel('Load profile')
plt.legend()
# Guardar la gráfica en un archivo PDF
```

```
plt.savefig("ARIMAX_14days.pdf", format="pdf", bbox_inches="tight")

plt.show()
```

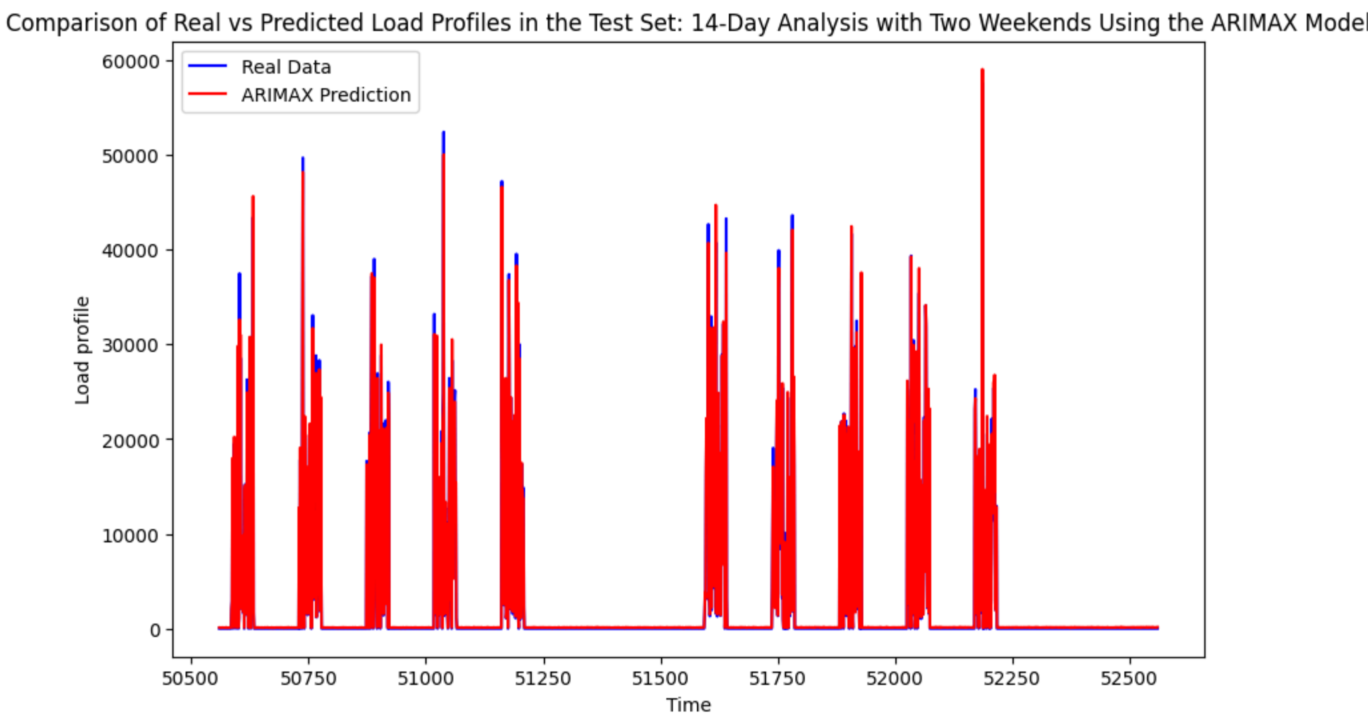


```
def plot_last_n_points(n=2000):
    """
    Función para graficar los últimos n puntos de los valores reales vs predichos.

    :param n: Número de puntos a graficar. Valor por defecto: 2000.
    """
    # Graficar los últimos n puntos de los valores reales vs predichos
    plt.figure(figsize=(10, 6))
    plt.plot(y_test.index[-n:], y_test.values[-n:], label='Real Data', color='blue')
    plt.plot(y_test.index[-n:], predictions[-n:], label='ARIMAX Prediction', color='red')
    plt.title('Real vs Predicted Load Profiles in the Test Set: 1-Day Analysis Using the ARIMAX Model')
    plt.xlabel('Time')
    plt.ylabel('Load profile')
    plt.legend()
    plt.savefig("arimax_1_DAY.pdf", format="pdf", bbox_inches="tight")
    plt.show()

# Llamar a la función con n=2000 o cualquier otro valor que desees
plot_last_n_points(n=400)
```

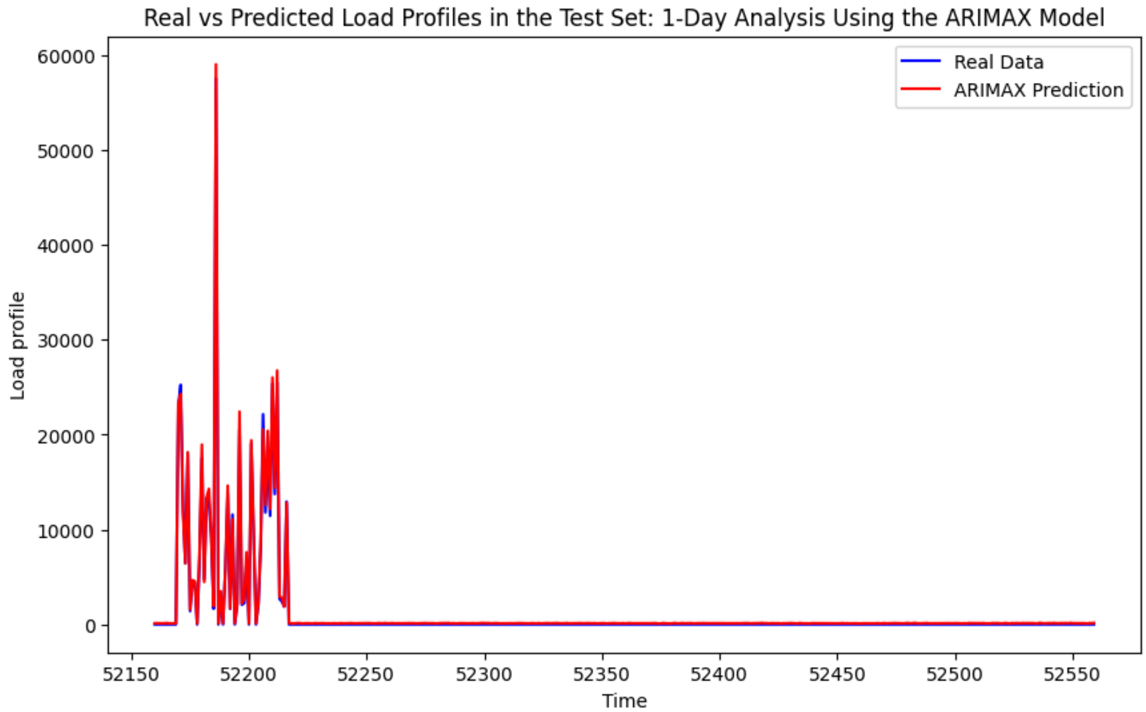

LSTM Model

```
import numpy as np
import pandas as pd
import tensorflow as tf
from sklearn.preprocessing import MinMaxScaler
from sklearn.metrics import mean_squared_error
import matplotlib.pyplot as plt

# Supongamos que 'df' es tu DataFrame con los datos

# Separar las características exógenas y la variable objetivo
X_exog = df.drop('perfil_carga', axis=1)  # Variables exógenas
y = df['perfil_carga']  # Variable objetivo (perfil_carga)

# Escalado de datos (opcional pero recomendado para LSTM)
scaler_X = MinMaxScaler()
scaler_y = MinMaxScaler()

X_exog_scaled = scaler_X.fit_transform(X_exog)
y_scaled = scaler_y.fit_transform(y.values.reshape(-1, 1))

# División basada en el tiempo (80% entrenamiento, 20% prueba)
train_size = int(len(y_scaled) * 0.8)
X_train_exog, X_test_exog = X_exog_scaled[:train_size], X_exog_scaled[train_size:]
y_train, y_test = y_scaled[:train_size], y_scaled[train_size:]

# Redimensionar los datos para LSTM (samples, time steps, features)
# Aquí vamos a suponer que los datos de entrada no tienen pasos de tiempo, es decir, un solo paso temporal por muestra
X_train_exog = X_train_exog.reshape((X_train_exog.shape[0], 1, X_train_exog.shape[1]))
X_test_exog = X_test_exog.reshape((X_test_exog.shape[0], 1, X_test_exog.shape[1]))

# Construcción del modelo LSTM
model = tf.keras.Sequential()

# Añadimos una capa LSTM
model.add(tf.keras.layers.LSTM(units=150, activation='tanh', return_sequences=False, input_shape=(X_train_exog.shape[1], X_train_exog.sha

# Capa densa para la salida
model.add(tf.keras.layers.Dense(1))

# Compilar el modelo
model.compile(optimizer='rmsprop', loss='mean_squared_error')

```

```
# Entrenamiento del modelo
history = model.fit(X_train_exog, y_train, epochs=20, batch_size=32, validation_data=(X_test_exog, y_test))

# Predicciones en el conjunto de prueba
y_pred_scaled = model.predict(X_test_exog)

# Desescalar las predicciones
y_pred = scaler_y.inverse_transform(y_pred_scaled)
y_test = scaler_y.inverse_transform(y_test)

# Calcular el RMSE entre los valores reales y las predicciones
rmse = np.sqrt(mean_squared_error(y_test, y_pred))
print(f'RMSE: {rmse}')

# Graficar el perfil de carga real vs predicho
plt.figure(figsize=(10, 6))
plt.plot(y_test, label='Datos reales', color='blue')
plt.plot(y_pred, label='Predicciones LSTM', color='red')
plt.title('Predicción LSTM vs Datos Reales')
plt.xlabel('Tiempo')
plt.ylabel('Perfil de Carga')
plt.legend()
plt.show()
```

```
/usr/local/lib/python3.10/dist-packages/keras/src/layers/rnn/rnn.py:204: UserWarning: Do not pass an `input_shape`/`input_dim` argument
  super().__init__(**kwargs)
Epoch 1/20
1314/1314 ━━━━━━━━━━━━━━━━━━━━ 5s 3ms/step - loss: 0.0015 - val_loss: 5.0616e-05
Epoch 2/20
1314/1314 ━━━━━━━━━━━━━━━━━━━━ 6s 4ms/step - loss: 8.6652e-05 - val_loss: 5.9346e-05
Epoch 3/20
1314/1314 ━━━━━━━━━━━━━━━━━━━━ 4s 3ms/step - loss: 7.7904e-05 - val_loss: 6.0098e-05
Epoch 4/20
1314/1314 ━━━━━━━━━━━━━━━━━━━━ 5s 4ms/step - loss: 7.1514e-05 - val_loss: 5.0620e-05
Epoch 5/20
1314/1314 ━━━━━━━━━━━━━━━━━━━━ 6s 4ms/step - loss: 6.8866e-05 - val_loss: 7.2178e-05
Epoch 6/20
1314/1314 ━━━━━━━━━━━━━━━━━━━━ 8s 3ms/step - loss: 6.9923e-05 - val_loss: 4.8991e-05
Epoch 7/20
1314/1314 ━━━━━━━━━━━━━━━━━━━━ 6s 4ms/step - loss: 6.4308e-05 - val_loss: 5.2579e-05
Epoch 8/20
1314/1314 ━━━━━━━━━━━━━━━━━━━━ 4s 3ms/step - loss: 6.4540e-05 - val_loss: 7.5513e-05
Epoch 9/20
1314/1314 ━━━━━━━━━━━━━━━━━━━━ 4s 3ms/step - loss: 6.4832e-05 - val_loss: 9.9684e-05
Epoch 10/20
1314/1314 ━━━━━━━━━━━━━━━━━━━━ 5s 3ms/step - loss: 6.2698e-05 - val_loss: 5.7568e-05
Epoch 11/20
1314/1314 ━━━━━━━━━━━━━━━━━━━━ 5s 3ms/step - loss: 6.2431e-05 - val_loss: 7.4076e-05
Epoch 12/20
1314/1314 ━━━━━━━━━━━━━━━━━━━━ 6s 4ms/step - loss: 5.9498e-05 - val_loss: 8.8135e-05
Epoch 13/20
1314/1314 ━━━━━━━━━━━━━━━━━━━━ 4s 3ms/step - loss: 5.8377e-05 - val_loss: 5.1028e-05
Epoch 14/20
1314/1314 ━━━━━━━━━━━━━━━━━━━━ 5s 3ms/step - loss: 5.9017e-05 - val_loss: 4.9580e-05
Epoch 15/20
1314/1314 ━━━━━━━━━━━━━━━━━━━━ 6s 4ms/step - loss: 5.6701e-05 - val_loss: 6.0958e-05
Epoch 16/20
1314/1314 ━━━━━━━━━━━━━━━━━━━━ 4s 3ms/step - loss: 5.8956e-05 - val_loss: 5.2897e-05
Epoch 17/20
1314/1314 ━━━━━━━━━━━━━━━━━━━━ 5s 3ms/step - loss: 5.4797e-05 - val_loss: 5.0678e-05
Epoch 18/20
1314/1314 ━━━━━━━━━━━━━━━━━━━━ 5s 4ms/step - loss: 5.8693e-05 - val_loss: 4.6704e-05
Epoch 19/20
1314/1314 ━━━━━━━━━━━━━━━━━━━━ 10s 4ms/step - loss: 5.5363e-05 - val_loss: 5.0701e-05
Epoch 20/20
1314/1314 ━━━━━━━━━━━━━━━━━━━━ 5s 3ms/step - loss: 5.4940e-05 - val_loss: 4.5278e-05
329/329 ━━━━━━━━━━━━━━━━━━━━ 1s 2ms/step
RMSE: 403.5594414359903
```

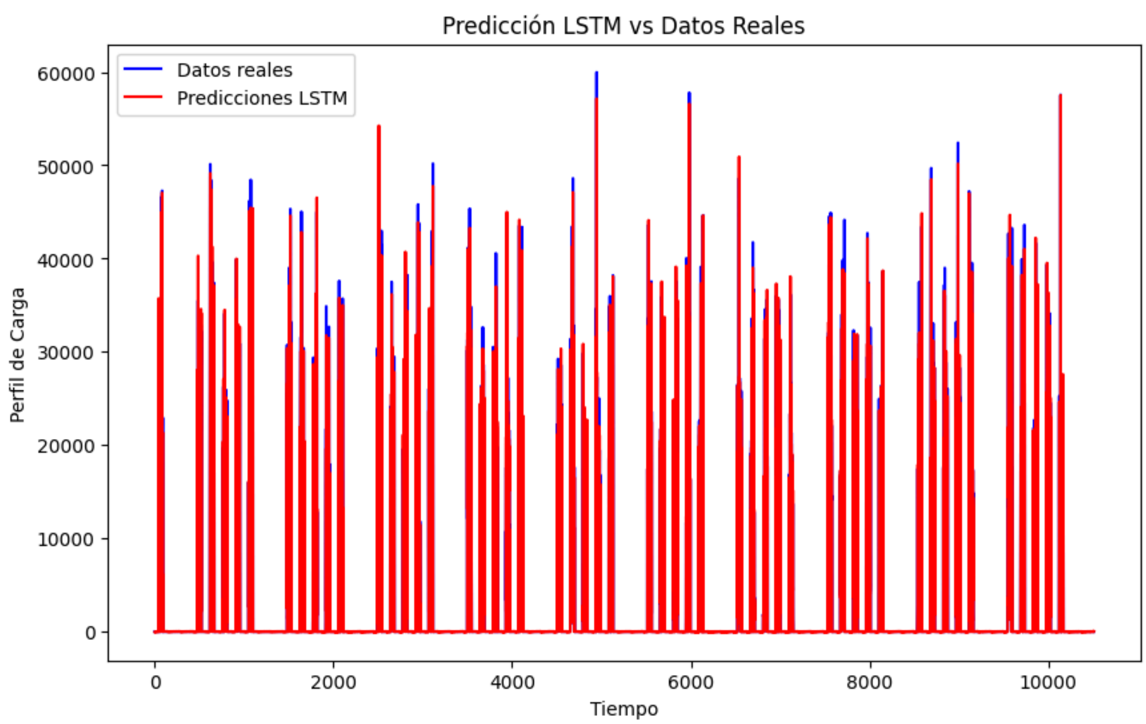


```
# Graficar el perfil de carga real vs predicho
plt.figure(figsize=(10, 6))
plt.plot(y_test, label='Real Data', color='blue')
plt.plot(y_pred, label='LSTM Prediction', color='red')
plt.title('LSTM Prediction vs Real Data in 1 year')
```

```python
plt.xlabel('Time')
plt.ylabel('Load profile')
plt.legend()
plt.savefig("lstm_year_all.pdf", format="pdf", bbox_inches="tight"
plt.show()
```

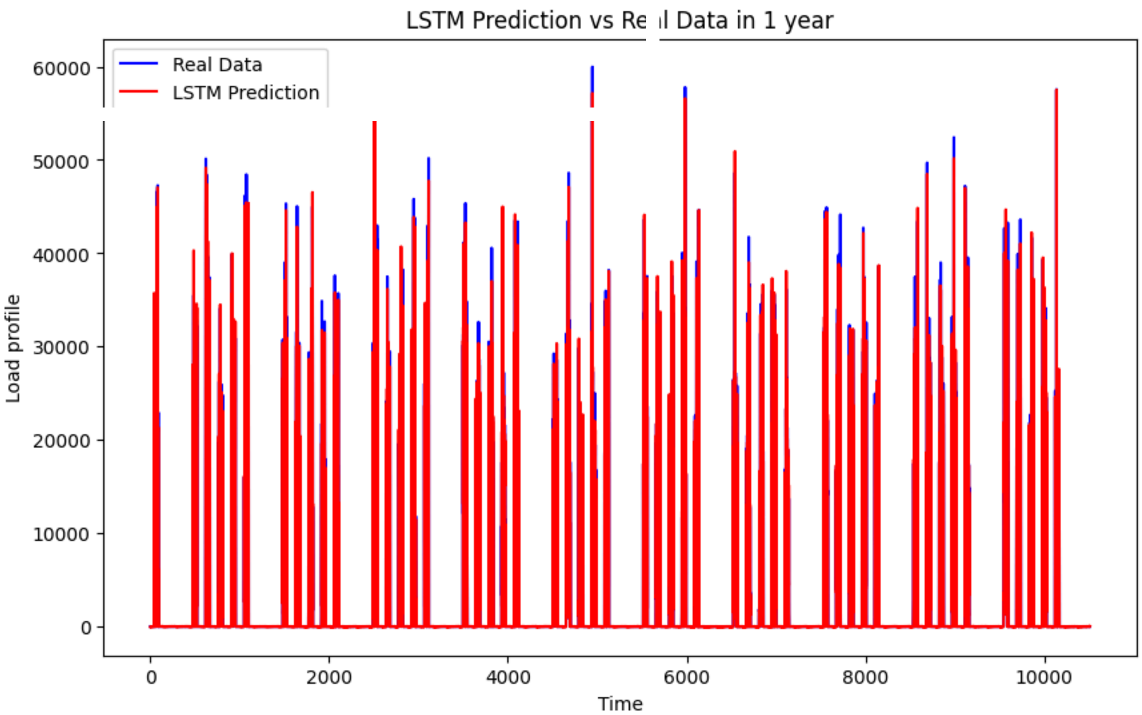


```python
def plot_last_n_points(y_test, y_pred, n=2000):
    """
    Función para graficar los últimos n puntos de los valores reales vs predichos.

    :param y_test: Valores reales.
    :param y_pred: Predicciones del modelo.
    :param n: Número de puntos a graficar. Valor por defecto: 2000.
    """
    # Graficar los últimos n puntos de los valores reales vs predichos
    plt.figure(figsize=(10, 6))
    plt.plot(y_test[-n:], label='Real Data', color='blue')
    plt.plot(y_pred[-n:], label=' LSTM Prediction', color='red')
    plt.title('LSTM Prediction vs Real Data in 14 days')
    plt.xlabel('Time')
    plt.ylabel('Load profile')
    plt.legend()
    plt.savefig("lstm_1_day.pdf", format="pdf", bbox_inches="tight")
    plt.show()

# Llamar a la función con n=2000 o cualquier otro valor que desees
plot_last_n_points(y_test, y_pred, n=2000)
```